

# Preparació de les eines: Estimació d'un quantil elevat

Esther Amores, Anna Costa i Oscar Ortiz

2/6/2021

Abans de començar amb la preparació de les eines, carreguem els paquets necessaris per tal d'executar les instruccions que es troben a continuació, així com també les dades `danish` del paquet `evir()`. Aquestes dades ens serviran com a referència per tal d'estimar els paràmetres d'una distribució power-law, així com també la distància de Kolmogorov-Smirnov.

```
# Paquets
library(poweRlaw)

# Dades
data("danish", package="evir")
```

**Programem en R la funció que dóna l'estimació màxim versemblant dels paràmetres d'una power-law.**

Creem una funció anomenada `ePL` que retorna  $\hat{\mu}$ , que és el valor mínim de les dades, el paràmetre estimat  $\alpha$  i el valor de la log-likelihood.

Donada una mostra  $\{x_1, x_2, \dots, x_m\}$  busquem la màxima versemblança d'una distribució power-law.

- La funció de densitat és:

$$f(x; \alpha, \mu) = \frac{\alpha}{\mu} \left( \frac{\mu}{x} \right)^{\alpha+1}$$

- La funció de versemblança és:

$$L(\alpha, \mu) = \alpha^n \mu^{n\alpha} \left( \prod_{i=1}^n x_i \right)^{-(\alpha+1)}, \quad (\mu \leq x_{\min})$$

- La funció log-versemblança és:

$$l(\alpha, \mu) = \log L(x) = n \cdot \log(\alpha) + n \cdot \alpha \cdot \log(\mu) - (\alpha + 1) \sum_{i=1}^n \log(x_i)$$

Fixat  $\alpha$  el màxim és  $\mu = x_{\min}$ . Així doncs, els paràmetres estimats d'una power-law són:

$$\hat{\mu} = x_{1,n}$$
$$\hat{\alpha} = \left[ \frac{1}{n} \sum_{i=1}^n \log \left( \frac{x_i}{x_{1,n}} \right) \right]^{-1} = \frac{1}{\xi}$$

que anomenarem `xm` i `alpha`, respectivament.

```
ePL <- function(xdt){
  xm <- min(xdt)
  xi <- mean(log(xdt/xm))
  n <- length(xdt)
  al <- 1/xi
  lpl <- n*log(al)+n*al*log(xm)-(al+1)*sum(log(xdt))
  list(min=xm, alpha=1/xi, lPL=lpl)
}

ePL(danish)
```

```
## $min
## [1] 1
##
## $alpha
## [1] 1.270729
##
## $lPL
## [1] -3353.128
```

Construïm un generador de nombres aleatoris per a la distribució power-law composant el generador d'uniformes,  $U(0,1)$ , amb la funció quantil.

La funció de distribució d'una power-law és:

$$F(x) = 1 - \left(\frac{x}{\mu}\right)^{-\alpha}$$

La funció quantil d'una distribució power-law es calcula fent  $F^{-1}(x) = y$  i aïllant la  $x$  d'aquesta equació. És a dir:

$$\begin{aligned} F^{-1}(x) &= 1 - \left(\frac{x}{\mu}\right)^{-1/\alpha} = y \\ \Leftrightarrow y - 1 &= - \left(\frac{x}{\mu}\right)^{-1/\alpha} \\ \Leftrightarrow (y - 1)^{-1/\alpha} &= -\frac{x}{\mu} \\ \Leftrightarrow x &= \mu(1 - y)^{-1/\alpha} \end{aligned}$$

$$Q(y) = F^{-1}(x) = \mu(1 - y)^{-1/\alpha}$$

```
rgpl <- function(mu, alpha, n, seed){
  set.seed(seed)
  y <- runif(n)
  x <- mu*((1-y)^(-1/alpha))
  return(x)
}
```

Validem les dades amb el test de Kolmogorov-Smirnov

```
mu <- 1
al <- 1

# Simulació d'un vector de dades aleatòries
x <- rgpl(mu=mu, alpha=al, n=10000, seed=1)

# Estadístic de contrast
X <- sort(x)
n <- length(X)
F <- 1-(X/mu)^(-al)
E <- seq(1:n)/n
D <- ks.test(x=F, y=E)$statistic[[1]]
est.con <- sqrt(n)*D

print(sprintf("est.con=%.3f, D=%.3f", est.con, D))
```

```
## [1] "est.con=0.900, D=0.009"
```

Veiem que per qualsevol dels valors d' $\alpha$  el resultat de l'estadístic de Kolmogorov-Smirnov,  $D$ , és el mateix (és a dir: 0.009).

Simulem dades d'una distribució power-law amb la funció de l'apartat anterior i verifiquem que la funció dóna l'estimació correcta, utilitzant el test de Kolmogorov-Smirnov.

$$D_n = \sup_{x_m < x < \infty} |F_n(x) - F_\alpha(x)|$$

En primer lloc, generem valors d'una distribució power-law amb paràmetres determinats  $\alpha$  i  $\mu$ . Després, calculem l'estadístic de contrast  $D$ . Aleshores, si  $X$  és un vector aleatori de dades  $\{x_1, x_2, \dots, x_n\}$  i  $X \sim PL(\alpha, \mu)$ , el test d'hipòtesis que avaluarem és el següent:

$$\begin{cases} H_0 &= X \sim PL(\alpha, \mu) \\ H_1 &= H_0 \text{ falsa} \end{cases}$$

Rebutjarem l'hipòtesi nul·la si  $\sqrt{n}D_n > k_\alpha$ .

```
mu <- 1
al <- 3

# Simulació d'un vector de dades aleatòries
x <- rgpl(mu=mu, alpha=al, n=10000, seed=1)

# Estadístic de contrast
X <- sort(x)
n <- length(X)
F <- 1-(X/mu)^(-al)
E <- seq(1:n)/n
D <- max(abs(E-F))
est.con <- sqrt(n)*D
print(sprintf("est.con=%.8f, D=%.8f", est.con, D))
```

```
## [1] "est.con=0.89300049, D=0.00893000"
```

$\alpha$	1
Punt crític	1.22
$\sqrt{n}D_n$	0.8930005

No tenim evidències per rebutjar la hipòtesi nul·la quan  $\alpha = 0.01, 0.05$  o  $0.10$  perquè cap dels estadístics de contrast obtinguts superen el llindar  $k_\alpha$ . Per tant, les dades generades segueixen una distribució power-law amb parametres  $\mu = 1, \alpha = 1$ .